

사회초년생, 고령자 및 구형 차량
운전자들을 위한 하이브리드 클라우드 기반
스마트폰 AI 블랙박스 시스템

컴퓨터공학과
22213485
박차오름

I. 서론


1. 문제 배경 및 필요성

현대 사회에서 자동차는 필수적인 이동 수단으로 자리 잡았으나, 안전한 주행 환경을 누리는 데에는 여전히 경제적·기술적 장벽이 존재한다. 특히 운전 경험이 부족한 사회초년생과 신체적 인지 능력이 저하되는 고령 운전자는 이러한 '안전 사각지대'에 놓인 대표적인 계층이다. 이들은 주로 경제적인 이유로 첨단 안전장치가 부재한 구형 차량을 이용하며, 이는 높은 사고율로 직결되고 있다. 본 프로젝트는 이러한 안전 취약 계층이 직면한 현실적인 문제와 기존 기술의 한계를 분석하고, 이를 해결하기 위한 새로운 접근 방식의 필요성을 제기한다.


(i) 안전 사각지대에 놓인 운전자들

사회초년생과 고령자의 구형 차량 이용 최근 지속되는 고물가와 경기 침체는 경제 활동 초기 단계에 있는 청년층의 부담을 가중시키고 있다. 이러한 경제적 제약으로 인해 사회초년생들은 첫 차로 상대적으로 진입 장벽이 낮은 구형 중고차를 선택하는 경향이 뚜렷하다.

한편, 급격한 고령화 사회로 진입하면서 은퇴 후 경제적 여건이 넉넉지 않은 65세 이상 고령 운전자 계층 역시 신차 교체보다는 기존의 구형 차량을 계속 이용하거나 저렴한 중고차를 구매하는 비중이 높다.



[그래프 I -1] 한국자동차모빌리티산업협회, 연령대별(청년층/고령층) 중고차 구매 비중



[그래프 I -2] 보험개발원(2023년 데이터), 연령대별 사고율 현황

[그래프 I -1]와 [그래프 I -2]의 통계 자료에서 확인할 수 있듯이, 사회초년생과 고령 운전자는 경제적인 이유로 노후화된 차량을 이용하는 비율이 높으며, 동시에 미숙한 운전 경험이나 노화로 인한 신체 능력 저하로 인해 사고 위험에 가장 크게 노출되어 있다.

근본적인 문제는 이들이 이용하는 구형 차량 대부분이 최신 차량에 기본으로 탑재되는 첨단 운전자 보조 시스템(ADAS)이나 고화질 블랙박스와 같은 안전장치를 갖추고 있지 않다는 점이다. 사고 발생 시 운전자를 보호하고 시시비비를 가릴 결정적인 증거 확보 수단이 부재한 상황이다. 안전을 위해 별도의 최신 장비를 장착하고자 해도, 기기 구매 및 설치에 드는 수십만 원의 경제적 부담은 이들에게 여전히 높은 진입 장벽으로 작용한다.

(ii) 기존 스마트폰 네비게이션 이용 환경의 한계

구형 차량에 내장된 순정 네비게이션은 지도 업데이트가 느리고 인터페이스가 불편하여, 대다수 운전자는 실시간 교통 정보를 반영하는 스마트폰 네비게이션 앱(티맵, 카카오내비 등)을 주행 중 메인으로 사용한다. 이러한 보편적인 사용자 행태는 스마트폰을 블랙박스 대용으로 활용하는 데 결정적인 걸림돌이 된다.

시중에는 스마트폰을 블랙박스로 활용할 수 있게 해주는 앱들이 존재하지만, 실제 주행 환경에서는 다음과 같은 치명적인 기술적 한계로 인해 외면받고 있다.

- 화면 점유 충돌 (UX 저해): 주행 중 스마트폰 화면은 운전자에게 길안내를 제공하는 네비게이션 앱이 점유해야 한다. 기존 블랙박스 앱을 동시에 실행할 경우, 카메라 화면이 네비게이션 지도 위에 오버레이(Overlay) 되어 시야를 가리거나, 네비게이션을 보기 위해 블랙박스 앱을 백그라운드로 전환하면 녹화가 중단되는 등 정상적인 사용 경험을 심각하게 해친다.

- 시스템 자원 한계 (발열 및 배터리): GPS와 화면을 지속적으로 사용하는 네비게이션 앱과 고화질 영상 녹화/인코딩을 수행하는 블랙박스 앱을 동시에 구동하는 것은 스마트폰에 극심한 부하를 준다. 이는 급격한 배터리 소모와 심각한 기기 발열을 유발하며, 장시간 주행 시 스로틀링(성능 저하)이 걸리거나 기기가 강제로 종료되어 네비게이션조차 볼 수 없게 되는 위험을 초래한다.

(iii) 핵심 문제 정의 및 해결의 시급성

앞서 분석한 경제적 제약, 구형 차량의 안전장치 부재, 그리고 기존 스마트폰 활용 기술의 한계를 종합해 볼 때, 현재 시장에는 사회초년생 및 고령 운전자를 위한 현실적인 안전 솔루션이 부재하다. 이들은 사고 위험이 가장 높은 취약 계층임에도 불구하고, 비용 부담과 사용의 불편함 때문에 최소한의 안전장치조차 마련하지 못하고 있는 실정이다.

따라서 본 프로젝트는 다음과 같은 핵심 문제를 정의하고 시급히 해결책을 모색하고자 한다.

"어떻게 하면 경제적인 부담 없이, 기존의 스마트폰 네비게이션 사용 습관을 전혀 해치지 않으면서, 사고 발생 시 운전자를 보호할 수 있는 신뢰성 높은 블랙박스 및 주행 분석 솔루션을 제공할 수 있을까?"

이 질문에 대한 해답을 찾는 것은 단순한 기술 개발을 넘어, 교통안전의 사각지대에 놓인 사회적 약자들에게 최소한의 디지털 안전망을 제공한다는 측면에서 시급하고 중요한 과제이다. 스마트폰 엣지(Edge)의 자원 한계를 극복하고 클라우드의 무한한 컴퓨팅 파워를 결합하는 새로운 패러다임의 접근이 필요한 시점이다.

2. 솔루션 제안: 하이브리드 클라우드 AI 블랙박스

앞서 제기된 사회초년생 및 고령 운전자의 현실적인 안전 문제와 기존 기술의 한계를 극복하기 위해, 본 프로젝트는 운전자가 이미 소유한 스마트폰을 엣지(Edge) 디바이스로 활용

용하고, 퍼블릭 클라우드의 강력한 컴퓨팅 자원을 연동하는 '하이브리드 클라우드 기반의 AI 블랙박스 시스템'을 제안한다.

(i) 제안 컨셉: 백그라운드 실시간 주행 분석 및 로그 시스템

우리가 제안하는 시스템의 핵심은 운전자가 기존의 스마트폰 네비게이션 앱(티맵, 카카오 내비 등)을 사용하는 습관을 전혀 해치지 않는 '무자각(Invisible) 백그라운드 서비스'를 구현하는 것이다.

운전자가 주행을 시작하고 네비게이션을 실행하면, 본 솔루션 앱은 화면 점유 없이 백그라운드에서 조용히 실행된다. 앱은 주행 영상을 일정 주기로 캡처하여 경량화된 통신 프로토콜을 통해 퍼블릭 클라우드 서버로 실시간 전송한다. 클라우드 서버는 전송받은 이미지를 대기 중인 고성능 AI 모델로 즉시 분석하여 전방 차량과의 거리, 차선 이탈 여부 등의 주행 안전 정보를 추출하고, 이를 구조화된 시계열 로그 데이터 형태로 기록한다. 이렇게 축적된 로그는 향후 사고 발생 시 객관적인 정황 증거 자료나, 운전자의 주행 습관을 분석하는 기초 데이터로 활용될 수 있다.

(ii) 기술적 난관: 엣지 디바이스(스마트폰)의 자원 한계 분석

이러한 '백그라운드 AI 블랙박스' 컨셉을 스마트폰 단독으로 구현하는 데는 명확하고 치명적인 기술적 한계가 존재한다.

- 제한된 컴퓨팅 자원과 배터리 : 스마트폰은 기본적으로 이동성을 위해 설계된 저전력 기기이다. 네비게이션 앱이 이미 많은 CPU 연산과 GPS, 화면 자원을 점유하고 있는 상태에서, 고해상도 영상 처리와 무거운 AI 추론 연산까지 동시에 수행하는 것은 불가능에 가깝다. 이는 기기의 심각한 발열로 인한 성능 저하와 급격한 배터리 소모를 유발하여, 주행 중 네비게이션이 종료되는 등 오히려 안전을 위협하는 결과를 초래할 수 있다.

- 모바일 OS의 백그라운드 프로세스 제약 : Android나 iOS와 같은 최신 모바일 운영체제는 사용자가 현재 보고 있는 포그라운드 앱의 성능과 배터리 사용 시간을 최우선으로 보장한다. 따라서 백그라운드 상태에 있는 앱이 카메라 리소스를 지속적으로 점유하거나 높은 CPU 사용량을 보일 경우, OS 차원에서 배터리 절약을 위해 해당 프로세스를 강제로 종료시키거나 리소스 접근을 엄격하게 제한한다.

(iii) 핵심 해결 전략: 하이브리드 클라우드 및 로컬 학습 파이프라인 도입

상기한 엣지 디바이스의 구조적 한계를 극복하고 안정적인 서비스를 제공하기 위해, 본 프로젝트는 각 컴퓨팅 환경이 가장 잘 수행할 수 있는 역할에 집중하는 하이브리드 아키텍처와 로컬 기반의 R&D 파이프라인을 핵심 전략으로 채택하였다.

Edge (스마트폰) - "경량화된 데이터 수집원": 스마트폰은 고부하 작업에서 완전히 해방된다. 백그라운드에서 카메라 영상을 캡처하고 이를 안정적으로 클라우드로 전송하는 최소한의 역할인 '데이터 소스' 기능에만 집중하여, 네비게이션 사용에 영향을 주지 않고 배터리 소모를 최소화한다.

Public Cloud (AWS/GCE) - "고성능 실시간 추론 및 데이터 허브": 무한한 확장성을 가진 클라우드 인프라가 무거운 연산 작업을 전담한다. 전송된 이미지를 안정적으로 수신하여 고성능 GPU 인스턴스에서 실시간 AI 추론을 수행하고, 분석된 결과 로그와 원본 데이터를 안전하게 저장하는 '서비스 코어' 역할을 수행한다.

AI 모델 고도화 전략 - "로컬 R&D 및 배포 파이프라인": 클라우드 비용 효율성과 개발 속도를 극대화하기 위해, AI 모델의 학습(Training)은 비싼 클라우드 자원 대신 고성능 로컬 GPU 장비를 갖춘 R&D 환경에서 수행한다. 실제 주행 데이터로 지속적으로 재학습되어 최적화된 커스텀 모델을 클라우드 추론 서버에 주기적으로 배포함으로써, 서비스 성능을 지속적으로 고도화하는 선순환 구조를 확립한다.

3. 프로젝트 목표 및 주요 기능

본 프로젝트는 앞서 정의한 안전 사각지대의 문제 상황을 해결하고 제안된 하이브리드 클라우드 솔루션을 실현하기 위해, 다음과 같이 최종 목표 시스템을 정의하고 이를 달성하기 위한 주요 기능 및 정량적인 평가지표를 설정한다.

(i) 최종 목표 시스템 정의

본 프로젝트의 최종 목표는 "경제적 여건이나 차량 연식과 관계없이, 모든 운전자가 스마트폰 하나로 누릴 수 있는 하이브리드 클라우드 기반의 보편적 AI 주행 안전 시스템"을 구축하는 것이다.

특히 사회초년생과 고령 운전자 등 안전 취약 계층이 별도의 고가 장비 구매 없이 기존

에 보유한 스마트폰을 활용하여 최소한의 안전망을 확보하는 데 초점을 맞춘다. 이 시스템은 운전자가 주행 중 네비게이션 앱을 사용하는 경험을 전혀 해치지 않도록 완벽한 백그라운드 환경에서 작동해야 한다. 스마트폰 엣지(Edge)는 최소한의 역할인 데이터 수집 및 전송만을 담당하고, 무한한 자원을 가진 퍼블릭 클라우드 인프라가 고성능 AI 분석을 전담함으로써, 실시간 주행 상황을 인지하고 사고 발생 시 객관적인 정황 증거가 될 수 있는 신뢰성 높은 주행 로그를 확보하는 것을 목표로 한다.

(ii) 주요 기능 및 평가지표 설정

최종 목표 시스템을 구현하기 위해 제공되어야 할 주요 핵심 기능은 다음과 같다.

Edge Client (React Native):

- 운전자 시야 방해 없는 무자각 백그라운드 서비스 실행 및 안정적인 카메라 제어
- 주행 영상의 주기적 캡처 및 이미지 최적화
- 모바일 네트워크 환경을 고려한 클라우드 서버로의 실시간 저지연 전송 모듈

Cloud Server (AWS Core):

- 다수의 엣지 클라이언트로부터 유입되는 대용량 실시간 이미지 데이터 수신 및 트래픽 부하 분산 (ALB)
- 로컬 R&D 환경에서 사전 학습된 커스텀 AI 모델(YOLOv8 기반)을 활용한 실시간 객체 감지(차량, 차선 등)
- 트래픽 변동 추이에 따라 컴퓨팅 자원을 자동으로 확장 및 축소하여 안정성을 보장하는 오토 스케일링

Data Platform (GCE Backend):

- AWS에 임시 적재된 원시 로그 데이터의 주기적 추출, 변환, 적재 실행
- 분석 결과의 체계적인 관리를 위한 구조화된 관계형 데이터베이스(Cloud SQL) 구축 및 영구 저장

프로젝트의 성공적인 목표 달성 여부를 객관적으로 검증하고 평가하기 위해, 핵심 성과 지표를 다음 [표 I -1]과 같이 정의하고 목표치를 설정한다. 이 지표들은 향후 [IV. 시스템 테스트 및 결과 분석] 장에서 성능 검증의 기준으로 활용된다.

구분	지표명	정의 및 측정 방법	목표치
AI 성능	모델 정확도	검증 데이터셋 기준 측정	> 80%

AI 성능	평균 추론 속도	클라우드 GPU 인스턴스에서 이미지 1장당 평균 처리 시간 측정	< 150ms
시스템 안정성	시스템 가동률	전체 운영 시간 대비 서비스가 정상적으로 제공된 시간의 비율 측정	> 99.9%
시스템 성능	종단간 지연 시간	엣지에서 이미지 캡처 시점부터 분석 결과가 DB에 저장되기까지 걸리는 총 시간	< 2초
확장성	오토 스케일링 반응 속도	임계치 초과 트래픽 발생 시점부터 신규 인스턴스가 서비스에 투입되기까지 걸리는 시간	< 3분

[표 I-1] 주요 평가지표 및 목표 설정

II. 시스템 설계 및 아키텍처

1. 전체 시스템 아키텍처 설계

본 장에서는 앞서 정의한 문제를 해결하기 위해 설계된 '하이브리드 클라우드 기반 AI 블랙박스 시스템'의 전체적인 아키텍처를 제시하고, 각 구성 요소의 역할과 데이터 흐름을 상세히 설명한다. 특히, Local, Edge, AWS, GCE라는 서로 다른 컴퓨팅 환경을 결합한 하이브리드 아키텍처를 채택하게 된 근거와 실제 구현된 시스템의 설계 철학을 중점적으로 기술한다.

(i) 하이브리드 클라우드(Local-Edge-AWS-GCE) 도입 근거 및 설계 철학

본 프로젝트는 스마트폰이라는 제한된 엣지 환경에서 고성능 AI 서비스를 제공해야 하는 근본적인 딜레마를 안고 있다. 이를 해결하기 위해 단일 환경에 의존하는 대신, 각기 다른 장점을 가진 네 가지 컴퓨팅 환경을 유기적으로 연결하는 하이브리드 파이프라인을 구축하였다. 이러한 설계의 핵심 철학은 "각 환경이 가장 잘하는 일에 집중하게 하여 전체 시스템의 효율성과 성능을 극대화하는 것"이다.

- Local (고성능 R&D) : AI 모델 학습은 막대한 연산 능력을 요구한다. 이를 비싼 클라우드 GPU로 감당하기에는 비용 부담이 크고 효율이 떨어진다. 따라서, 이미 보유하고 있는 고성능 로컬 GPU(RTX 4070 Super) 자원을 활용하여 모델 연구개발(R&D) 및 학습을 전담시킴으로써 비용 효율성과 개발 속도를 확보하였다.

- Edge (경량화된 접점) : 스마트폰은 사용자와 가장 가깝지만 자원이 제한적이다. 따라


서 네비게이션 구동에 방해가 되지 않도록 무거운 추론 작업은 배제하고, 데이터(영상) 수집 및 실시간 전송이라는 최소한의 역할만 부여하여 안정성을 확보하였다.

- AWS Cloud (실시간 서비스 코어) : 전송된 데이터를 실시간으로 처리해야 하는 추론 작업은 탄력적인 자원 운용이 가능한 AWS에 맡겼다. 트래픽 변화에 유연하게 대응할 수 있는 고가용성 인프라를 통해 안정적인 대국민 서비스를 제공하는 것을 목표로 한다.

- GCE Cloud (데이터 웨어하우스) : AWS에 임시 저장된 로그는 장기 보관 및 분석을 위해 별도의 데이터 플랫폼으로 이관한다. 구글의 강력한 데이터 분석 및 관리형 DB 서비스를 활용하여 체계적인 데이터 웨어하우스를 구축하였다.

(ii) 전체 시스템 구성도 및 데이터 흐름 상세 정의

상기한 설계 철학을 바탕으로 구현된 전체 시스템의 아키텍처는 다음 [그림 II-1]과 같다. Local에서 학습된 AI 모델이 AWS로 배포되고, Edge에서 수집된 데이터가 AWS를 거쳐 GCE로 최종 저장되는 종단간(End-to-End) 데이터 흐름을 시각적으로 보여준다.



[그림 II-1] 하이브리드 클라우드 기반 전체 시스템 아키텍처 및 데이터 흐름도

[그림 II-1]에 도시된 시스템의 주요 데이터 흐름은 다음과 같이 단계별로 상세 정의된다.

- AI 모델 학습 및 배포 (Local → AWS) : 로컬 R&D 환경에서 고성능 GPU를 활용해

실제 주행 데이터로 커스텀 YOLOv8 모델을 학습시킨다. 최적화가 완료된 모델 가중치 파일(best.pt)은 AWS EC2 추론 서버로 안전하게 배포(전송)되어 탑재된다.

- 데이터 수집 및 실시간 전송 (Edge → AWS) : 스마트폰의 백그라운드 앱은 주행 중 카메라 영상을 주기적(3초 간격)으로 캡처한다. 캡처된 이미지는 최적화 과정을 거친 후, AWS의 Application Load Balancer(ALB) 엔드포인트로 실시간 전송된다.

- 부하 분산 및 실시간 추론 (AWS 내부) : ALB는 유입되는 트래픽을 감지하여 사설 서브넷(Private Subnet)에 위치한 다수의 건강한 EC2 추론 인스턴스로 부하를 분산시킨다. 각 EC2 인스턴스는 탑재된 커스텀 AI 모델을 활용하여 수신된 이미지에 대한 실시간 객체 감지(차량, 차선) 추론을 수행한다.

- 1차 로그 적재 (AWS 내부) : 추론 결과(탐지된 객체 정보, 처리 시간 등)는 메타데이터 형태로 추출되어, AWS S3 버킷에 CSV 형식의 임시 로그 파일로 실시간 적재된다.

- 데이터 이관 (AWS → GCE) : GCE 환경에 구축된 VM 인스턴스가 스케줄러에 의해 주기적으로 실행되며 ETL 파이프라인을 가동한다. AWS S3에 접근하여 새로 생성된 로그 파일을 추출하고, 분석에 용이한 형태로 변환한다.

- 최종 데이터 적재 및 저장 (GCE 내부) : 변환된 구조화 데이터는 GCE의 관리형 데이터베이스인 Cloud SQL(MySQL)의 정해진 테이블 스키마에 최종적으로 적재되어 영구 보관 및 관리된다.

2. 주요 Cloud 리소스 활용 정의 및 역할

본 프로젝트는 AWS의 탄력적인 인프라와 GCP의 데이터 관리 역량을 결합한 하이브리드 클라우드 전략을 채택하였다. AWS는 엣지로부터 유입되는 실시간 트래픽을 처리하고 AI 추론을 수행하는 '서비스 코어' 역할을, GCP는 추론된 데이터를 가공하여 영구적으로 저장하고 관리하는 '데이터 웨어하우스' 역할을 담당한다.

각 클라우드 플랫폼에서 활용된 주요 리소스의 상세 정의와 선정 근거, 그리고 시스템 내 핵심 역할은 다음과 같다.

(i) Amazon AWS (핵심 추론 및 인프라 스트럭처) 리소스별 상세 역할

AWS는 불특정 다수의 스마트폰 클라이언트로부터 발생하는 예측 불가능한 실시간 트래픽을 안정적으로 수용하고, 고성능 AI 모델을 기반으로 즉각적인 추론 결과를 제공하는 핵심 인프라로 구성된다.

분류	리소스명	주요 역할 및 선정 근거
Compute	EC2	실시간 AI 추론 서버 - 역할: 로컬에서 사전 학습된 커스텀 YOLOv8 모델 - 선정 근거: 실시간 영상 추론은 높은 연산 능력을 요구한다. 서버리스 환경의 콜드 스타트 지연 시간이나 리소스 제약을 피하고, 고성능 컴퓨팅 환경에 대한 완전한 제어권을 확보하기 위해 EC2를 선택.
	Auto Scaling Group	단력적 자원 관리 및 고가용성 보장 - 역할: 출퇴근 시간 등 트래픽 변동에 따라 EC2 인스턴스 수를 자동으로 확장하거나 축소한다. - 선정 근거: 예측 불가능한 사용자 트래픽에 유연하게 대응하여 서비스 안정성을 보장하고, 유휴 시간대에는 불필요한 인스턴스를 종료하여 비용 효율성을 극대화하기 위해 필수적이다.
Network	ALB (Application Load Balancer)	트래픽 부하 분산 및 단일 진입점 - 역할: 스마트폰 앱의 모든 요청을 받아 다수의 Healthy EC2 인스턴스로 트래픽을 균등하게 분산시킨다. - 선정 근거: 단일 서버의 과부하를 방지하고, 특정 인스턴스 장애 시 자동으로 트래픽을 우회시켜 서비스 연속성을 보장하는 고가용성 아키텍처 구현을 위해 채택함.
Storage	S3	로그 데이터 버퍼 및 중간 저장소 - 역할: EC2에서 분석된 추론 결과 메타데이터(CSV 로그)를 실시간으로 저장한다. - 선정 근거: 내구성이 뛰어나고 무제한 확장이 가능한 객체 스토리지이다. 특히 AWS와 GCP 사이에서 데이터를 임시 보관하고 비동기적으로 연동하기 위한 안정적인 버퍼이다.
Security	Security Group & IAM	계층별 보안 및 권한 관리 - 역할: ALB는 80/443 포트만 허용, EC2는 ALB로부터의 트래픽만 허용하는 등 인스턴스 레벨의 방화벽을 구성한다. IAM Role을 통해 EC2가 액세스 키 없이 안전하게 S3에 접근하도록 권한을 위임한다. - 선정 근거: 최소 권한 원칙에 입각한 보안 환경 구축을 위해 필수적이라 채택함.

[표 II-1] AWS 주요 리소스 활용 정의 및 선정 근거

(ii) Google Cloud Platform (데이터 파이프라인 및 DW) 리소스별 상세 역할

GCP는 AWS에 임시 저장된 비정형 로그 데이터를 주기적으로 추출하여 구조화된 형태로 변환하고, 이를 영구적으로 보관 및 관리하기 위한 백엔드 데이터 플랫폼으로 활용된다.

분류	리소스명	주요 역할 및 선정 근거
Compute	Compute Engine (VM Instance)	ETL 파이프라인 실행 서버 - 역할: Python 기반의 ETL(Extract, Transform, Load) 스크립트가 Cron 스케줄러에 의해 주기적으로 실행되는 서버이다. AWS S3에 접근하여 새 로그를 가져오고 데이터베이스에 적재하는 파이프라인의 주체이다. - 선정 근거: 복잡한 데이터 엔지니어링 도구 대신, Python 스크립트 기반의 경량화된 ETL 작업을 수행하기에는 비용 효율적이고 제어가 간편한 기본 VM 인스턴스가 가장 적합하다고 판단하였다.
Database	Cloud SQL (MySQL)	최종 구조화 데이터 저장소 - 역할: ETL 과정을 거쳐 정제된 주행 분석 데이터(시간, 위치, 탐지된 객체 수 등)가 관계형 테이블 형태로 최종 저장되는 데이터베이스이다. - 선정 근거: 추후 사고 이력 조회나 통계 분석을 위해서는 구조화된 데이터 조회가 필수적이다. DB 서버를 직접 구축/관리하는 부담(백업, 패치, 고가용성 등)을 덜고 데이터 활용에만 집중하기 위해 완전 관리형 RDBMS 서비스인 Cloud SQL을 선택하였다.

[표 II -2] GCP 주요 리소스 활용 정의 및 선정 근거

3. 세부 설계 고려사항 및 트레이드오프 분석

본 시스템의 하이브리드 아키텍처는 다양한 기술적 대안들 사이에서의 고민과 분석의 결과물이다. 특히 '어디서 연산을 수행할 것인가(Edge vs Cloud)'와 '이기종 클라우드를 어떻게 연결할 것인가'는 시스템의 성패를 가르는 핵심적인 의사결정 사항이었다. 본 절에서는 이러한 주요 설계 결정의 배경과 근거를 상세히 기술한다.

(i) 엣지 vs 클라우드 역할 분담 기준 수립

가장 큰 고민은 고부하 작업인 'AI 실시간 추론'을 수행할 주체를 결정하는 것이었다. 스마트폰 자체에서 처리하는 '온디바이스(On-device) Edge 추론' 방식과 서버로 전송하여 처리하는 'Cloud 추론' 방식을 두고, 본 프로젝트의 타겟 사용자(구형 차량/폰 보유자)와 사용 시나리오(네비게이션 동시 사용)를 기준으로 트레이드오프를 분석하였다.

비교 항목	스마트폰 처리	Cloud 기반 추론 [채택]
시스템 자원 점유	높음 - 네비게이션과 GPU/CPU 자원 경합 발생 - 심각한 발열 및 배터리 광탈 유발	매우 낮음 - 단순 영상 캡처 및 전송만 수행 - 기기 발열 최소화 및 배터리 효율 극대화
사용자 경험 (UX)	나쁨 - 발열로 인한 스로틀링으로 네비게이션 버벅임 또는 강제 종료 위험 존재	우수 - 백그라운드 작동으로 포그라운드 앱(네비게이션) 성능에 영향을 최소화 함.
AI 모델 성능	제한적 - 모바일 리소스 한계로 경량화된 모델(예: YOLO Nano)만 사용 가능하여 정확도 타협 필요	높음 - 고성능 서버 자원을 활용하여 무겁지만 정확도가 높은 모델(예: YOLOv8 Large)으로의 활용 가능성 있음.
네트워크 의존성	낮음 (오프라인 동작 가능)	높음 (네트워크 음영 지역에서 서비스 불가)
구형 기기 호환성	낮음 (최신 NPU 탑재 기기 유리)	높음 (카메라와 통신 기능만 있다면 구형 기기에서도 고성능 AI 서비스 이용 가능)

[표 II-3] AI 추론 주체 결정에 따른 트레이드오프 분석 비교

[결정 근거] 분석 결과, 스마트폰 처리는 네트워크 지연이 없다는 장점이 있으나, 본 프로젝트의 핵심 전제 조건인 '구형 기기 지원'과 '쾌적한 네비게이션 동시 사용'을 완벽하게 위배한다. 특히 주행 중 발열로 인해 네비게이션이 종료되는 상황은 안전에 치명적이다. 반면, Cloud 기반 추론은 네트워크 의존성이라는 단점이 존재하지만, 옛지 기기의 부하를 획기적으로 줄여 안정성을 확보하고 기기 사양과 무관하게 고성능 AI 모델을 적용할 수 있다는 점에서 본 프로젝트의 목표에 부합하는 유일하고 현실적인 대안으로 판단하여 채택하였다. 네트워크 지연 문제는 이미지 최적화와 경량 프로토콜 사용을 통해 최소화하는 방향으로 설계하였다.

(ii) 이기종 클라우드(AWS-GCE) 간 데이터 연동 방식 선정 이유

AWS(추론 코어)와 GCP(데이터 웨어하우스)라는 두 개의 이기종 클라우드를 활용함에 따라, 두 환경 간의 효율적이고 안정적인 데이터 연동 방안이 필요했다. 실시간으로 생성되는 추론 데이터를 어떻게 GCP의 데이터베이스로 옮길 것인가에 대해 '동기식 직접 호출'과 '비동기식 버퍼링' 방식을 비교 분석하였다.

비교 항목	동기식 직접 호출	비동기식 버퍼링 (S3) [채택]
작동 방식	AWS EC2가 추론 직후, GCP API를 호출하여 DB에 직접 데이터를 삽입하고 응답을 기다림.	AWS EC2는 추론 결과를 S3에 파일로 저장하고 즉시 다음 작업을 수행. GCP VM이 주기적으로 S3를 확인하여 데이터를 가져감.
실시간성	높음 (추론 즉시 DB 반영)	준 실시간 (ETL 스케줄링 주기에 따른 약간의 지연 발생)
결합도	높음 (강한 결합, GCP 측 장애 발생 시 AWS 추론 서버까지 응답 지연되거나 오류가 전파됨)	낮음 (약한 결합, GCP 측 장애가 발생해도 AWS 추론 서비스는 영향 없이 S3에 데이터를 계속 적재 가능)
시스템 복잡도	낮음	중간 (별도의 ETL 파이프라인 및 스케줄러 구현 필요)
안정성 및 확장성	낮음 (병목 현상 취약)	높음 (S3의 높은 내구성을 활용하여 데이터 유실 방지. 트래픽 폭증 시 버퍼 역할 수행.)

[표 II-4] 클라우드 간 데이터 연동 방식 비교 분석

[결정 근거] 본 시스템에서 가장 중요한 것은 앞단인 'AWS 실시간 추론 서비스'의 무중단 안정성이다. 동기식은 구조가 간단하지만, GCP 백엔드의 장애나 네트워크 지연이 AWS 프론트엔드 서비스의 장애로 즉시 전파되는 치명적인 위험(결합도가 높음)이 있다. 따라서, 다소 구현 복잡도가 증가하고 약간의 데이터 반영 지연이 발생하더라도, 시스템 간의 의존성을 최소화(Decoupling)하여 전체적인 안정성을 극대화할 수 있는 'S3를 활용한 비동기식 버퍼링' 방식을 채택하였다. AWS는 GCP의 상태와 상관없이 S3에 데이터를 안전하게 '던져놓기(Fire-and-Forget)'만 하면 되므로, 핵심 추론 서비스의 높은 가용성을 유지할 수 있다.


4. 네트워크 및 보안 아키텍처 설계

본 프로젝트는 불특정 다수의 스마트폰 단말기와 연결되며, 민감할 수 있는 주행 영상 데이터를 다루는 만큼 견고한 네트워크 및 보안 아키텍처 설계가 필수적이다. 이를 위해 AWS의 격리된 네트워크 환경인 VPC를 기반으로 퍼블릭/프라이빗 서브넷 계층 구조를 설계하고, 제로 트러스트 원칙에 입각한 접근 제어 및 전 구간 암호화 통신 전략을 수립하였

다.

(i) AWS VPC 서브넷(Public/Private) 구성 및 라우팅 설계

서비스의 안정성과 보안성을 확보하기 위해, AWS 서울 리전(ap-northeast-2) 내에 논리적으로 완전히 격리된 가상 네트워크 공간인 VPC를 구축하였다. 이 VPC 내부는 외부 인터넷 접근 가능 여부에 따라 퍼블릭 서브넷과 프라이빗 서브넷으로 계층화하여 구성하였다.



[그림 II -2] AWS VPC 내부 네트워크 토폴로지 및 보안 그룹 구성도

퍼블릭 서브넷

- 구성 : 인터넷 게이트웨이(IGW)와 라우팅되어 외부 인터넷과 직접 통신이 가능한 영역이다.
- 배치 리소스 : 외부 트래픽의 유일한 진입점인 ALB(Application Load Balancer)와 프라이빗 인스턴스의 아웃바운드 통신을 지원하는 NAT Gateway를 이 영역에 이중화 (Multi-AZ)하여 배치하였다. 외부 공격에 직접 노출되는 영역이므로 최소한의 리소스만 배치하여 공격 표면을 최소화했다.

프라이빗 서브넷

- 구성 : 외부 인터넷에서 직접적인 접근이 불가능한 격리된 영역이다. 오직 퍼블릭 서브

넷에 위치한 ALB를 통해서만 인바운드 트래픽을 수신할 수 있다.

- 배치 리소스 : 서비스의 핵심인 EC2 추론 인스턴스들과 Auto Scaling 그룹을 이 영역에 배치하여, 외부의 직접적인 해킹 시도로부터 원천적으로 보호한다.

라우팅

- 인바운드 : 외부(Edge) → IGW → ALB(Public Subnet) → EC2(Private Subnet) 순으로 트래픽이 전달된다.
- 아웃바운드 : EC2(Private Subnet)가 S3 접근이나 외부 API 호출 등을 위해 인터넷으로 나갈 때는, Public Subnet에 위치한 NAT Gateway를 경유하여 안전하게 아웃바운드 통신을 수행한다.

(ii) 클라우드 보안 그룹(Security Group) 및 IAM 권한 관리 설계

네트워크 계층 격리에 이어, 인스턴스 및 애플리케이션 레벨에서의 세밀한 접근 제어를 위해 AWS의 보안 그룹과 IAM 역할을 활용하였다.

보안 그룹(Security Group) - 인스턴스 방화벽

- '최소 권한 원칙'을 적용하여, 명시적으로 허용된 트래픽 외에는 모두 차단(Deny-All)하는 화이트리스트 방식으로 정책을 수립하였다.
- ALB SG : 외부(Anywhere, 0.0.0.0/0)로부터 들어오는 HTTPS(443) 트래픽만 허용한다.
- EC2 SG : 오직 'ALB가 속한 보안 그룹'으로부터 들어오는 애플리케이션 포트(Flask 5000번) 트래픽만 허용한다. 이를 통해 ALB를 거치지 않은 비정상적인 접근 시도를 완벽하게 차단한다.

IAM 역할(Role) 기반 권한 관리

- EC2 인스턴스가 추론 로그를 S3 버킷에 업로드하기 위해서는 S3 접근 권한이 필요하다.
- 이때 소스 코드 내에 영구적인 액세스 키(Access Key ID/Secret Key)를 하드코딩하는 것은 심각한 보안 위험을 초래한다.
- 이를 방지하기 위해, S3 쓰기 권한만 부여된 IAM 역할을 생성하고 이를 EC2 인스턴스 프로파일에 연결하였다. 이를 통해 EC2는 별도의 자격 증명 관리 없이 안전하게 임시 보안 토큰을 발급받아 S3 서비스에 접근한다.

(iii) 데이터 전송 구간 암호화 전략

엣지, AWS, GCE를 오가는 모든 데이터는 공용 인터넷망을 통과하므로, 데이터 도청 및 변조를 방지하기 위해 전 구간 암호화 통신(Encryption in Transit)을 적용하였다.

Edge (스마트폰) ↔ AWS (ALB) 구간

- 스마트폰 앱이 이미지를 전송할 때 표준 HTTPS (TLS/SSL) 프로토콜을 사용한다. AWS Certificate Manager(ACM)를 통해 발급받은 SSL 인증서를 ALB에 적용하여, 클라이언트와 로드밸런서 간의 통신을 암호화한다.

AWS (EC2) → AWS (S3) 구간

- EC2에서 S3로 로그 파일을 업로드할 때 사용되는 AWS SDK(Boto3)는 기본적으로 HTTPS 엔드포인트를 사용하여 통신하므로 데이터가 암호화되어 전송된다.

AWS (S3) ↔ GCP (VM) 구간

- GCP의 ETL VM이 AWS S3에서 데이터를 추출할 때 역시 AWS SDK 또는 CLI를 사용하며, 이 과정 또한 HTTPS를 통해 안전하게 암호화되어 인터넷 구간을 통과한다.

GCP (VM) → GCP (Cloud SQL) 구간

- GCP 내부 네트워크를 통한 통신이지만, Cloud SQL 접속 시 SSL 연결을 강제하여 ETL 서버와 DB 간의 데이터 전송 안전성을 추가로 확보하였다.

III. 핵심 기술 구현 및 클라우드 인프라 구축 상세

본 장에서는 제안한 하이브리드 AI 블랙박스 시스템을 실제 구현하기 위한 핵심 기술 개발 과정과 클라우드 인프라 구축 내역을 상세히 기술한다. 시스템의 두뇌에 해당하는 AI 모델은 고성능 로컬 GPU 환경에서 자체 데이터셋을 기반으로 개발되었으며, 이를 서비스하기 위한 인프라는 AWS와 GCP를 활용하여 구축되었다.

1. [Phase 1: Local AI R&D] 고성능 GPU 기반 커스텀 AI 모델 개발

실시간 주행 상황 인지를 위한 AI 모델 개발은 막대한 컴퓨팅 자원을 필요로 한다. 본 프로젝트는 클라우드 비용 절감과 개발 효율성을 극대화하기 위해, 고성능 로컬 GPU 장비를 활용하여 데이터 구축부터 모델 학습, 최적화까지 수행하는 독자적인 R&D 파이프라인을 구축하였다.

(i) 개발 환경 구축: 로컬 GPU(RTX 4070 Super) 활용 딥러닝 환경 셋업

1) 하드웨어 구성 최신 객체 인식 모델(YOLOv8)의 빠른 학습과 대용량 데이터 처리를 위해 NVIDIA GeForce RTX 40 시리즈 GPU를 탑재한 고성능 데스크탑을 활용하였다. 상세 스펙은 다음 [표 III-1]과 같다.

구분	부품명	상세 사양	비고
CPU	i7-13700k	16 Cores / 24 Threads	
GPU	RTX 4070 super	VRAM 12GB GDDR6X	CUDA : 7168
RAM	DDR5 32GB		
Storage	512GB + 256GB +240GB	SSD	

[표 III-1] 로컬 AI 개발 환경 하드웨어 상세 스펙

(ii) 소프트웨어 스택 및 GPU 가속 설정

Windows 환경에서 리눅스 기반의 딥러닝 프레임워크를 원활히 구동하기 위해 WSL2(Windows Subsystem for Linux 2)를 도입하고 Ubuntu 22.04, 24.04 LTS 환경을 구축하였다. GPU 가속을 위해 NVIDIA Driver, CUDA Toolkit, cuDNN 라이브러리를 설치하였으며, PyTorch 프레임워크와 호환성을 검증하였다.

```
PS C:\Users\smp05> nvidia-smi
Thu Nov 27 00:34:03 2025
```

NVIDIA-SMI 576.88			Driver Version: 576.88			CUDA Version: 12.9		
GPU	Name	Perf	Driver-Model	Bus-Id	Disp.A	Volatile	Uncorr. ECC	
Fan	Temp		Pwr:Usage/Cap		Memory-Usage	GPU-Util	Compute M. MIG M.	
0	NVIDIA GeForce RTX 4070	...	WDDM	00000000:01:00.0	On		N/A	
0%	30C	P0	35W / 220W	1689MiB / 12282MiB		7%	Default N/A	

Processes:							
GPU	GI ID	CI ID	PID	Type	Process name	GPU Memory Usage	
0	N/A	N/A	3464	C+G	...y\Comet\Application\comet.exe	N/A	
0	N/A	N/A	3688	C+G	...2024\HOffice130\Bin\HCell.exe	N/A	
0	N/A	N/A	6468	C+G	...e 2024\HOffice130\Bin\Hwp.exe	N/A	
0	N/A	N/A	9800	C+G	...em32\ApplicationFrameHost.exe	N/A	
0	N/A	N/A	11004	C+G	...Chrome\Application\chrome.exe	N/A	
0	N/A	N/A	12088	C+G	...0.3595.94\msedgewebview2.exe	N/A	
0	N/A	N/A	14396	C+G	C:\Windows\explorer.exe	N/A	
0	N/A	N/A	16636	C+G	...ication\4.34.340.19\whale.exe	N/A	
0	N/A	N/A	17336	C+G	...y\StartMenuExperienceHost.exe	N/A	
0	N/A	N/A	18132	C+G	...ntrolPanel\SystemSettings.exe	N/A	
0	N/A	N/A	18632	C+G	...ms\Microsoft VS Code\Code.exe	N/A	
0	N/A	N/A	20148	C+G	...0.3595.94\msedgewebview2.exe	N/A	
0	N/A	N/A	20624	C+G	...__kzh8wxbdkxb8p\DCv2\DCv2.exe	N/A	
0	N/A	N/A	21328	C+G	...indows\System32\ShellHost.exe	N/A	
0	N/A	N/A	21528	C+G	...IA App\CEF\NVIDIA Overlay.exe	N/A	
0	N/A	N/A	22508	C+G	...8bbwe\PhoneExperienceHost.exe	N/A	
0	N/A	N/A	25780	C+G	...IA App\CEF\NVIDIA Overlay.exe	N/A	
0	N/A	N/A	25912	C+G	..._cw5n1h2txyewy\SearchHost.exe	N/A	
0	N/A	N/A	26508	C+G	...xyewy\ShellExperienceHost.exe	N/A	
0	N/A	N/A	26980	C+G	...2txyewy\CrossDeviceResume.exe	N/A	
0	N/A	N/A	27996	C+G	...5n1h2txyewy\TextInputHost.exe	N/A	
0	N/A	N/A	29248	C+G	...Chrome\Application\chrome.exe	N/A	
0	N/A	N/A	30548	C+G	...0.3595.94\msedgewebview2.exe	N/A	
0	N/A	N/A	30588	C+G	...0.3595.94\msedgewebview2.exe	N/A	
0	N/A	N/A	33856	C+G	...yb3d8bbwe\WindowsTerminal.exe	N/A	

[그림 III-1] 개발 환경 내 GPU 인식 및 CUDA 설정 확인

(iii) 데이터 수집 및 가공 파이프라인


실제 도로 환경에서 신뢰성 높은 성능을 발휘하는 AI 모델을 만들기 위해, 공개된 데이터셋 대신 유튜브에 촬영된 실제 주행 영상을 기반으로 커스텀 데이터셋을 구축하였다.

1) 주행 영상 데이터 수집 시나리오

다양한 주행 환경을 반영하기 위해 다음과 같은 시나리오를 수립하여 각 상황별 100장

분량의 주행 사진을 스마트폰으로 수집하였다.

- 수집 장비: Galaxy S25+
- 설치 위치: 모니터에 표시되는 자동자 대시보드 위
- 주행 조건: 도심지(시내 주행), 고속도로(고속 주행), 주간(맑음/우천), 야간(맑음/우천) 등 다양한 환경 데이터 확보




[그림 III-2] 다양한 환경에서 수집된 실제 주행 영상 데이터 샘플

2) Roboflow 기반 커스텀 객체(차량, 차선) 라벨링 및 데이터셋 구축 현황

수집된 원본 영상에서 프레임 단위로 이미지를 추출한 후, 컴퓨터 비전 데이터 플랫폼인 Roboflow를 활용하여 정밀한 데이터 라벨링 작업을 수행하였다.

- 탐지 객체(Class) 정의 : 주행 안전과 직결된 차량(Car)과 차선(Lane), 트럭(Truck), 사람(Person) 네 가지 클래스를 정의하였다. 차량은 전방에 위치한 승용차만을 의미한다. 차선은 자차가 주행 중인 차로의 좌우 실선/점선, 트럭은 트럭, 버스를 포함한 큰 차, 사람은 사람을 대상으로 하였다.
- 라벨링 작업 : 추출된 이미지에서 각 클래스에 해당하는 객체를 Roboflow에서 제공하

는 Smart Polygon 기능으로 영역을 잡고, 실제 학습시에는 이를 박스 좌표로 변환하여 바운딩 박스로 라벨링을 하는 작업을 수행하였다.



[그림 III-3] Roboflow 플랫폼을 활용한 차량 및 차선 객체 라벨링 작업 화면


(iv) AI 모델 학습 및 최적화 과정 상세

구축된 고품질의 자체 데이터셋을 바탕으로, 실시간 추론에 적합한 최신 객체 인식 알고리즘을 선정하고 로컬 GPU 환경에서 학습 및 최적화를 진행하였다.

1) YOLOv8 알고리즘 선정 이유 및 기술적 특징

본 프로젝트의 핵심 요구사항인 '실시간성'과 '높은 정확도'를 동시에 만족시키기 위해 Ultralytics사의 YOLOv8 알고리즘을 선정하였다.

YOLOv8은 이미지 전체를 한 번에 보는 1-stage detector 방식으로 빠른 추론 속도를 제공한다. 이전 버전에 비해 개선된 백본 네트워크 구조와 Anchor-free 탐지 헤드를 도입하여, 작은 객체나 겹쳐진 객체에 대한 인식 성능이 향상되었다. 이는 다양한 거리와 크기의 차량을 놓치지 않고 탐지해야 하는 주행 환경에 적합한 특성이다.



[그림 III-4] YOLOv8 네트워크 아키텍처 구조도

2) 모델 학습 하이퍼파라미터 설정 및 학습 과정 시각화

YOLOv8 모델 중 모바일 환경 추론을 고려하여 경량화된 'Nano' 버전을 베이스 모델로 선택하고, 자체 구축한 데이터셋으로 전이 학습을 수행하였다. 학습 효율을 높이기 위해 주요 하이퍼파라미터를 다음과 같이 설정하였다.


names:

- car
- lane
- person
- truck

```
nc: 4
roboflow:
  license: CC BY 4.0
  project: lane-car-detection-real-63e0w
  url: https://universe.roboflow.com/orm-v3brw/lane-car-detection-real-63e0w/dataset/1
  version: 2
  workspace: orm-v3brw
test: ../train/images
train: ../train/images
val: ../train/images
```

data.yaml (데이터셋 구성 설정)


학습이 진행되는 동안 모델의 예측 오차를 나타내는 손실(Loss) 값의 변화 추이를 모니터링하였다.



[그림 III-5] version: 1, 학습 진행에 따른 Loss(손실) 및 mAP(정확도) 변화 그래프

[그림 III-5]의 그래프 분석 결과, 100 에포크 동안 학습 및 검증 단계의 모든 손실 값들이 지속적으로 하락하며 안정적으로 수렴하고 있어 과적합 없이 일반화가 잘 이루어졌음을 알 수 있고, 이에 따라 정밀도와 재현율이 꾸준히 상승했다. 특히 종합적인 성능 지표인 mAP50이 0.97에 육박하고 mAP50-95가 약 0.9에 도달한 것으로 보아 정확도가 높다는 것을 알 수 있다.

(v) 최적 모델(best.pt) 선정 기준 및 검증 결과 (mAP 지표 등)



[표 III-6] 최적 모델(best.pt)의 최종 검증 데이터셋 평가 결과

최종 선정된 모델은 기존 100개에 300개의 데이터를 추가했음에도 불구하고 mAP50-95가 0.87에 육박하는 성능을 그대로 유지한 모델이다. 통상적으로 데이터 다양성이 늘어나면 학습 곡선이 흔들릴 수 있지만, 이번 결과는 손실 값이 매끄럽게 수렴하여 추가된 데이터의 패턴까지 완벽하게 소화했음을 보여준다. 수치상의 점수는 이전과 비슷해 보일지라도 더 넓은 범위의 데이터를 커버할 수 있는 일반화 성능이 강화된 모델을 채택했다.

2. [Phase 2: AWS Cloud Implementation] 실시간 추론 인프라 구축

앞선 Phase 1에서 개발된 고성능 AI 모델을 서비스에 투입하기 위해, AWS 퍼블릭 클라우드 환경에 안정적이고 확장 가능한 실시간 추론 인프라를 구축하였다. 설계된 보안 아키텍처에 따라 격리된 네트워크 환경을 구성하고, 추론 서버 애플리케이션을 구현하였으며, 트래픽 변동에 유연하게 대응하기 위한 고가용성 및 오토 스케일링 구성을 완료하였다.

(i) AWS 기본 네트워크 인프라 구축 과정 (VPC, Subnet, IGW, NAT 구성 실습)

[II. 시스템 설계 및 아키텍처]에서 설계한 네트워크 토폴로지를 AWS 서울 리전(ap-northeast-2)에 실제로 구현하였다. 외부 공격으로부터 시스템을 보호하기 위해 논리적으로 격리된 VPC 환경을 구축하고 계층화된 서브넷을 구성하였다.

1) VPC 및 서브넷 구성

10.0.0.0/16 CIDR 블록을 가진 VPC를 생성하고, 4개의 가용 영역에 걸쳐 외부 통신을 위한 2개의 Public Subnet과 추론 서버 보호를 위한 2개의 Private Subnet을 각각 생성하였다.

Name	서브넷	상태	VPC	리전	IPv4	IPv6	사설 ...	가용 ...	네트...	라우팅 테이블
-	subnet-	Available	vpc-065...	고기	172.31...	-	4091	apne2-a...	ap-nort...	rtb-0ad8688cc6de27b81
-	subnet-	Available	vpc-065...	고기	172.31...	-	4090	apne2-a...	ap-nort...	rtb-0ad8688cc6de27b81
-	subnet-	Available	vpc-065...	고기	172.31...	-	4091	apne2-a...	ap-nort...	rtb-0ad8688cc6de27b81
lane-subnet-private1...	subnet-	Available	vpc-0b7...	고기	10.0.12...	-	4089	apne2-a...	ap-nort...	rtb-0634f2a8b26c326d1 lane...
lane-subnet-public1...	subnet-	Available	vpc-0b7...	고기	10.0.0.0...	-	4088	apne2-a...	ap-nort...	rtb-05e8d95ea78b8a289 lane...
lane-subnet-public2...	subnet-	Available	vpc-0b7...	고기	10.0.16...	-	4089	apne2-a...	ap-nort...	rtb-05e8d95ea78b8a289 lane...
-	subnet-	Available	vpc-065...	고기	172.31...	-	4091	apne2-a...	ap-nort...	rtb-0ad8688cc6de27b81
lane-subnet-private2...	subnet-	Available	vpc-0b7...	고기	10.0.14...	-	4090	apne2-a...	ap-nort...	rtb-015ed280675c988358 lane...

[그림 III-7] 구축된 VPC 서브넷 목록 및 가용 영역 배치 현황 (AWS 콘솔 화면)

2) 인터넷 게이트웨이(IGW) 및 NAT 게이트웨이 구성

Public Subnet이 외부 인터넷과 통신할 수 있도록 IGW를 생성하여 연결하였으며, Private Subnet에 위치한 인스턴스가 외부(S3, 패키지 리포지토리 등)로 나가는 아웃바운드 통신만 가능하도록 각 AZ의 Public Subnet에 NAT Gateway를 구축하고 라우팅 테이블을 설정하였다.

Name	라우팅 테이블 ID	연속적 서브넷 연결	연지 연결	기본	VPC	소유자
-	rtb-0ad8688cc6de27b81	-	-	예	vpc-06547fd7eb5d0e94	66691
lane-rtb-public	rtb-05e8d95ea78b8a289	공 서브넷	-	아니요	vpc-0b7805ac8f99a3413 lane...	66691
lane-rtb-private2-ap-northeast-2b	rtb-059d180675c988358	subnet-071c3bc50e0ad1...	-	아니요	vpc-0b7805ac8f99a3413 lane...	66691
lane-rtb-private1-ap-northeast-2a	rtb-0634f2a8b26c326d1	subnet-05cb0e52e34e3c...	-	아니요	vpc-0b7805ac8f99a3413 lane...	66691
-	rtb-0f76d8f86cc700c2	-	-	예	vpc-0b7805ac8f99a3413 lane...	66691

[그림 III-8] Public 및 Private 서브넷 라우팅 테이블 설정 화면

2.1) AI 추론 서버(EC2) 구현 및 환경 설정

격리된 Private Subnet 내에서 실제 AI 추론 작업을 수행할 EC2 인스턴스를 구현하고, 필수적인 소프트웨어 환경을 설정하였다.

2.1.1) EC2 인스턴스 타입 선정 근거 및 OS 환경 설정

실시간 영상 추론을 위해 비용 효율성과 연산 성능의 균형을 고려하여 인스턴스 타입을 선정하였다.

서버 역할	호스트명	인스턴스 타입	주요 사양	선정 근거 및 전략
Bastion Host	lane-bastion	t3.micro	2vCPU/1GiB	프리 티어 활용 및 최소 리소스 할당 Bastion Host는 프라이빗 서브넷 접근을 위한 단순 SSH 중계 서버 역할만 수행한다. 애플리케이션 로직을 처리하지 않으므로 CPU 및 메모리 사용량이 극히 낮으므로 채택했다.
Backend Server	lane-server-private	t3.small	2vCPU/2GiB	애플리케이션 안정성을 위한 최소 요구사항 충족 백엔드 서버는 OS 구동 외에도 웹 프레임워크, 데이터 처리 런타임 등을 위한 기본 메모리가 필요하다. t3.micro는 1GiB로 메모리가 부족하여 Out of Memory 오류가 발생할 위험이 높다. 따라서 프리 티어에서 활용 가능한 한 단계 높은 t3.small을 채택했다.

[표 III-2] 역할별 EC2 인스턴스 타입 선정 및 근거

OS 환경: 딥러닝 프레임워크 호환성이 뛰어난 Ubuntu Server 22.04 LTS를 기반 이미지로 선택하였다.

2.2) Python Flask 기반 추론 API 서버 구현


EC2 인스턴스 상에서 스마트폰으로부터 전송된 이미지를 받아, Phase 1에서 개발한 best.pt 모델로 추론하고 그 결과를 JSON으로 반환하는 경량 웹 애플리케이션을 Python Flask 프레임워크를 활용하여 구현하였다.

2.2.1) 커스텀 AMI(Amazon Machine Image) 생성 과정

오토 스케일링을 통해 인스턴스가 자동으로 확장될 때, 매번 초기 설정을 반복하지 않고 즉시 서비스에 투입될 수 있도록 구성이 완료된 EC2 상태를 커스텀 AMI로 이미지화하였다.

- 베이스 EC2 인스턴스에 Python, PyTorch, Ultralytics, Flask 등 필수 라이브러리 설치.

- best.pt 모델 파일과 app.py 서버 코드 업로드.
- 서버 부팅 시 Flask 앱이 자동으로 실행되도록 systemd 서비스(flaskapp.service) 등록.
- 구성이 완료된 인스턴스를 정지하고, AWS 콘솔에서 '이미지 생성' 수행.



[그림 III-9] 추론 서버 환경이 패키징된 커스텀 AMI 목록


2.3) 고가용성 및 확장성 구현 (ALB & Auto Scaling)

트래픽 폭증 시에도 안정적인 서비스를 제공하고 단일 지점 장애를 방지하기 위해 로드 밸런싱과 오토 스케일링을 구성하였다.

2.3.1) Application Load Balancer(ALB) 대상 그룹 설정 및 트래픽 분산 테스트

Public Subnet에 ALB를 배치하여 외부의 HTTPS 요청을 수신하도록 설정하였다. ALB가 트래픽을 전달할 대상으로 Private Subnet에 위치한 EC2 인스턴스들을 지정하는 '대상 그룹'을 생성하였다.

상태 검사 설정: ALB가 인스턴스의 정상 작동 여부를 판단할 수 있도록, Flask 서버에 상태 검사 전용 경로를 구현하고, ALB가 주기적으로 해당 경로를 호출하여 200 OK 응답을 확인하도록 설정하였다.




[그림 III-10] ALB 대상 그룹 내 인스턴스 상태 검사(Health Check) 통과 화면

2.3.2) Auto Scaling Group(ASG) 시작 템플릿 작성 및 동적 조정 정책 설정 (CPU 부하 기준)

- 사용자 트래픽에 따라 EC2 인스턴스 수를 자동으로 조절하기 위해 Auto Scaling Group(ASG)을 구성하였다.
- 시작 템플릿: 앞서 생성한 커스텀 AMI ID, 인스턴스 타입, 보안 그룹(ALB 접근 허용), IAM 역할 정보를 정의하여 인스턴스 생성의 기준 도면을 작성하였다.
- 동적 조정 정책(Dynamic Scaling Policy): 추론 작업은 CPU(또는 GPU) 집약적이므로, '평균 CPU 사용률'을 기준으로 하는 대상 추적(Target Tracking) 정책을 설정하였다.

목표값 설정: 평균 CPU 사용률 60% 유지 (60% 초과 시 스케일 아웃, 미만 시 스케일 인)



[그림 III-11] CPU 사용률 기반 Auto Scaling 동적 조정 정책 설정 화면

2.4) 로그 데이터 저장소(S3) 구성 및 접근 권한 설정

추론된 결과 데이터를 임시 저장하고 GCP로 이관하기 위한 버퍼로 AWS S3 버킷을 생성하였다.

- 버킷 생성: 로그 데이터 저장을 위한 전용 S3 버킷을 서울 리전에 생성하였다.

- IAM 역할 기반 접근 권한 부여: EC2 인스턴스가 액세스 키 하드코딩 없이 안전하게 S3에 로그 파일을 업로드할 수 있도록, 최소 권한이 부여된 IAM 역할을 생성하고 이를 EC2 인스턴스 프로파일에 연결하였다.



[그림 III-12] 로그 저장용 S3 버킷 생성 및 EC2 IAM 역할 연결 화면

3. [Phase 3: Edge Client Development] 스마트폰 백그라운드 앱 구현

하이브리드 시스템의 최전방 데이터 수집원 역할을 수행하는 안드로이드 기반의 엣지 클라이언트 앱을 구현하였다. 본 앱의 주요 목적은 주행 중 카메라 하드웨어를 제어하여 영상을 획득하고, 이를 클라우드 추론 서버가 처리할 수 있는 형태로 최적화하여 실시간으로 전송하는 것이다. 이를 위해 카메라 제어, 이미지 처리, 네트워크 전송 등 핵심 기능을 모듈화하여 구현하였다.


(i) React Native 앱 주요 컴포넌트 및 구조

엣지 앱은 React Native (Expo) 프레임워크 기반으로 구현되어 크로스 플랫폼 호환성을 확보하였으며, UI 계층과 비즈니스 로직 계층으로 구분된 모듈형 아키텍처를 채택하였다.

- 메인 컴포넌트 (UI Layer): 앱의 진입점으로, 카메라 뷰와 AR 오버레이를 조합하여 사용자에게 실시간 영상과 감지 결과를 동시에 제공하는 인터페이스를 구현한다. React Hooks를 활용하여 상태 관리(차선/차량 데이터, FPS, 처리 시간 등)와 생명주기 관리를 수행한다.
- AR 오버레이 컴포넌트 (Presentation Layer): 카메라 뷰 위에 투명하게 겹쳐지는 AR(Augmented Reality) 레이어로, 서버로부터 받은 감지 결과를 시각화한다. React

Native SVG를 활용하여 벡터 그래픽 기반의 고성능 렌더링을 구현하였다.

- Socket Manager: WebSocket 기반 실시간 양방향 통신을 담당하는 모듈로, AWS 클라우드 서버와의 지속적인 연결을 유지한다.
- 이미지 캡처 및 최적화: Expo Camera API를 통해 카메라 하드웨어를 제어하고, 캡처된 이미지를 전송에 최적화된 형태로 변환한다.
- 데이터 수신 및 상태 동기화: 서버로부터 받은 감지 결과를 파싱하여 React 상태로 동기화하고, AR 오버레이 업데이트를 트리거한다.



[그림 III-13] 스마트폰 엡지 앱 주요 컴포넌트 구조도

(ii) 카메라 제어 및 이미지 캡처 최적화 구현

카메라 하드웨어에 접근하여 이미지를 획득하고, 이를 클라우드로 전송하기 효율적인 형태로 최적화하는 로직을 구현하였다.

- 카메라 접근 및 캡처: React Native의 Expo Camera API를 활용하여 크로스 플랫폼 카메라 제어를 구현하였다. 앱이 실행되는 동안 후면 카메라 세션을 유지하며, 비동기 타이머를 통해 150ms 스로틀링 간격으로 프레임을 캡처한다. 이전 프레임의 처리가 완료되기 전에는 새로운 프레임을 캡처하지 않는 플래그 기반 제어를 통해 과도한 네트워크 요청을 방지하였다.
- 이미지 최적화: 카메라에서 획득한 원본 고해상도 이미지를 그대로 전송하는 것은 불필요한 대역폭을 소모하고 추론 서버의 부하를 가중시킨다. 따라서 캡처 직후 Expo

Image Manipulator를 사용하여 AI 모델의 입력 크기에 맞춰 너비 640px로 리사이징하고, JPG 포맷으로 압축한 후 Base64 인코딩하여 WebSocket 전송에 최적화된 형태로 변환한다. 이를 통해 데이터 크기를 수십 KB 단위로 최소화하는 최적화 과정을 거친다.

(iii) WebSocket 기반 클라우드 실시간 이미지 전송 모듈 구현

최적화 과정을 거친 Base64 인코딩 형태의 이미지 데이터를 AWS 클라우드에 구축된 ALB 엔드포인트로 실시간 전송하기 위해 안정적인 양방향 통신 모듈을 구현하였다.

- 네트워킹 라이브러리 활용: React Native 환경에서 실시간 통신을 위한 표준 라이브러리인 Socket.IO Client를 사용하여 안정적인 WebSocket 기반 양방향 통신 환경을 구축하였다.
- Base64 비동기 전송: 이미지 데이터를 WebSocket 이벤트 메시지에 실어 보내기 위해 Base64 인코딩 방식을 사용하였다. 메인 UI 스레드가 멈추는 현상을 방지하기 위해, 모든 이미지 캡처 및 전송 작업은 비동기 방식으로 수행되며, 이전 프레임 처리가 완료되기 전에는 새로운 프레임을 전송하지 않는 플래그 기반 제어 메커니즘을 적용하였다.

4. [Phase 4: GCP Data Pipeline] 데이터 웨어하우스 구축

하이브리드 아키텍처의 최종 단계로, AWS S3에 임시 버퍼링된 비정형 추론 로그 데이터를 주기적으로 추출하여 분석 가능한 형태로 구조화하고, 이를 Google Cloud Platform(GCP)의 관리형 데이터베이스에 영구 저장하는 자동화된 데이터 웨어하우스 파이프라인을 구축하였다. 이를 통해 데이터의 장기 보관성과 활용성을 확보한다.

(i) Google Cloud Platform 환경 설정 및 서비스 계정 연동

안정적인 데이터 파이프라인 운영을 위해 GCP 내에 필요한 컴퓨팅 및 데이터베이스 리소스를 생성하고, AWS 리소스에 접근하기 위한 보안 설정을 수행하였다.

- GCP 리소스 구성: ETL 스크립트를 실행할 컴퓨팅 환경으로 Compute Engine (GCE VM) 인스턴스(e2-micro, Ubuntu 22.04 LTS)를 생성하였으며, 최종 데이터를 저장할 관리형 관계형 데이터베이스로 Cloud SQL for MySQL 인스턴스를 구축하였다.



[그림 III-14] GCP Compute Engine(VM) 및 Cloud SQL 인스턴스 생성 현황

- 이기종 클라우드 간 보안 연동: GCE VM에서 실행되는 파이썬 스크립트가 AWS S3 버킷에 접근할 수 있도록 권한 설정이 필요하다. 이를 위해 AWS IAM에서 S3 읽기 권한만 부여된 전용 사용자의 액세스 키와 비밀 키를 발급받아, GCE VM 내부의 별도 디렉토리에 배치하였다.

(ii) AWS CLI 기반 데이터 추출 및 분석

AWS S3에 저장된 실시간 주행 데이터(이미지 + 감지 로그)를 추출하여 다양한 교통 안전 분석 및 운전자 보조 시스템 개선에 활용할 수 있는 기반을 마련하였다.

1) AWS CLI를 활용한 S3 데이터 다운로드

AWS Management Console의 S3 서비스 또는 AWS CLI를 통해 저장된 데이터를 로컬 환경으로 다운로드하여 분석에 활용할 수 있다.

[방법 1] AWS S3 웹 콘솔 UI를 통한 다운로드

S3 서비스 선택 -> lane-data-2025-oreum 선택 -> logs/data.csv 파일 선택 -> 다운로드
S3 서비스 선택 -> lane-data-2025-oreum 선택 -> raw_data/ 폴더에서 이미지 다운로드

[방법 2] AWS CLI를 통한 명령줄 다운로드

```
# CSV 로그 파일 다운로드
aws s3 cp s3://lane-data-2025-oreum/logs/data.csv
```

```
# 원본 이미지 데이터 일괄 다운로드 (선택적)
aws s3 sync s3://lane-data-2025-oreum/raw_data/.
```

1.2) 교통 안전 분석 및 운전자 보조 시스템 개선 방안

수집된 데이터는 특정 운전자 그룹의 안전 운전 지원 및 사고 예방을 위한 다양한 분석 시나리오에 활용할 수 있다.

1.2.1) 사회초년생 운전자를 위한 위험 상황 학습 데이터

활용 목적:

운전 경험이 부족한 신규 운전자들에게 실제 주행 환경에서 발생 가능한 위험 상황(급차선 변경, 차량 밀집 구간 등)을 사전 학습할 수 있는 교육 자료로 활용

분석 시나리오:

- 차량 밀집도 분석: 감지된 차량 수가 3대 이상인 고위험 구간 이미지 추출
- 차선 이탈 빈도: 차선이 제대로 감지되지 않는 구간(터널, 야간) 패턴 파악
- 처리 시간 지연 구간: 감지 시간이 평균 이상 소요된 복잡한 교통 상황 식별

1.2.2) 고령 운전자를 위한 사고 예방 및 보조 시스템 최적화


활용 목적:

반응 속도가 느린 고령 운전자를 위한 선제적 경고 시스템 개발 및 ADAS(첨단 운전자 보조 시스템) 민감도 조정

분석 시나리오:

- 위험 거리 임계값 설정: 차량 간 거리가 15m 이하인 급접근 상황 빈도 분석
- 차선 유지 보조 데이터: 좌우 차선 감지 성공률을 기준으로 차선 이탈 경고 타이밍 최적화
- 시간대별 사고 위험도: 야간/일몰 시간대의 감지 정확도 저하 구간 파악

1.2.3) 데이터 수집 및 활용 워크플로우



[그림 III-15] 데이터 수집 및 활용 워크플로우

(iii) Cloud SQL 데이터베이스 스키마 설계 및 구축

AWS S3에서 추출 및 변환 과정을 거친 구조화된 주행 분석 데이터를 GCP의 Cloud SQL(MySQL)에 영구적으로 적재(Load)하기 위해 관계형 데이터베이스 스키마를 설계하였다.

설계의 주안점은 시계열로 지속적으로 쌓이는 대량의 로그 데이터를 효율적으로 저장하고, 향후 특정 시간대나 특정 조건(예: 차량 감지 수 급증 구간)에 대한 빠른 조회 및 통계 분석이 가능하도록 하는 것이다. 이를 위해 메인 로그 테이블인 lane_db를 정의하고, 시간 기준 조회의 성능을 높이기 위해 타임스탬프 필드에 인덱스를 적용하였다.

주요 데이터를 저장하는 메인 테이블의 상세 명세는 다음 [표 III-3]과 같다.

필드명	데이터 타입	설명
timestamp	DATETIME	이미지 캡처 시각 또는 분석 시각
filename	VARCHAR(255)	분석 대상이 된 원본 이미지 파일의 이름
car_count	INT	해당 이미지에서 탐지된 차량의 총 개수
lane_count	INT	해당 이미지에서 탐지된 차선의 총 개수
processing_time_ms	FLOAT	AWS EC2에서 해당 추론 처리에 걸린 소요 시간

[표 III-3] Cloud SQL 데이터베이스 테이블 명세서 (테이블명: lane_db)

MySQL Workbench

GCE_DB x

File Edit View Query Database Server Tools Scripting Help

Navigator

SCHEMAS

Q. Filter objects

lane_db

Tables

detection_logs

Columns

- timestamp
- filename
- car_count
- lane_count
- processing_time_ms

Indexes

Foreign Keys

Triggers

Views

Stored Procedures

Functions

sys

Administration Schemas

Information

Query 1 x

Limit to 1000 rows

```

1
2 SELECT * FROM detection_logs
3 ORDER BY timestamp DESC
4 LIMIT 20;

```

Result Grid

Filter Rows:

Edit: Export/Import: Wrap Cell Cor

timestamp	filename	car_count	lane_count	processing_time_ms
2025-11-30 12:20:08	20251130_122008_331427.jpg	2	2	134.33
2025-11-30 12:20:04	20251130_122004_599683.jpg	1	2	135.12
2025-11-30 12:20:00	20251130_122000_213535.jpg	1	2	172.78
2025-11-30 12:19:56	20251130_121956_809849.jpg	1	2	133.08
2025-11-30 12:19:53	20251130_121953_411395.jpg	2	2	138.45
2025-11-30 12:19:49	20251130_121949_801904.jpg	1	2	130.73
2025-11-30 12:19:46	20251130_121946_409481.jpg	1	2	132.98
2025-11-30 12:19:42	20251130_121942_908946.jpg	1	2	141.79
2025-11-30 12:19:39	20251130_121939_207621.jpg	1	2	135.15
2025-11-30 12:19:35	20251130_121935_928636.jpg	2	2	127.93
2025-11-30 12:19:32	20251130_121932_608227.jpg	0	2	128.11
2025-11-30 12:19:29	20251130_121929_249682.jpg	1	2	148.59
2025-11-30 12:19:25	20251130_121925_869275.jpg	1	2	134.74
2025-11-30 12:19:22	20251130_121922_315360.jpg	1	2	130.48
2025-11-30 12:19:18	20251130_121918_857241.jpg	2	2	150.83
2025-11-30 12:19:15	20251130_121915_437615.jpg	1	2	159.13
2025-11-30 12:19:11	20251130_121911_854336.jpg	2	2	156.35
2025-11-30 12:19:08	20251130_121908_440124.jpg	2	2	161.37
2025-11-30 12:19:05	20251130_121905_080614.jpg	3	2	158.27
2025-11-30 12:19:01	20251130_121901_573112.jpg	0	2	230.88

[그림 III-16] Cloud SQL에 실제로 저장된 lane_db 테이블 데이터

IV. 시스템 테스트 및 결과 분석

1. 평가 개요 및 환경

(i) 평가 목표 및 성과 지표 검증 계획

여기에서는 구현된 '하이브리드 클라우드 기반 AI 블랙박스 시스템'이 설계 목표를 충족하는지 검증하기 위해 단계별 성능 평가를 수행한다. 순서는 아래와 같다.

- AI 모델의 객체 인식 정확도
- 클라우드 인프라의 트래픽 처리 능력

- 엣지에서 데이터 웨어하우스까지의 전체 데이터 흐름 안정성

특히 서론에서 설정한 모델 정확도 80% 이상, 지연 시간 2초 미만, 시스템 가동률 99.9% 달성 여부를 중점적으로 확인한다.

구분	지표명	정의 및 측정 방법	목표치
AI 성능	모델 정확도	검증 데이터셋 기준 측정	> 80%
AI 성능	평균 추론 속도	클라우드 GPU 인스턴스에서 이미지 1장당 평균 처리 시간 측정	< 150ms
시스템 안정성	시스템 가동률	전체 운영 시간 대비 서비스가 정상적으로 제공된 시간의 비율 측정	> 99.9%
시스템 성능	종단간 지연 시간	엣지에서 이미지 캡처 시점부터 분석 결과가 DB에 저장되기까지 걸리는 총 시간	< 2초
확장성	오토 스케일링 반응 속도	임계치 초과 트래픽 발생 시점부터 신규 인스턴스가 서비스에 투입되기까지 걸리는 시간	< 3분

[표 IV-1] 시스템 성능 검증을 위한 평가 항목 및 목표치

1) 테스트 평가 환경

객관적인 성능 평가를 위해 학습 단계에서 사용되지 않은 다양한 환경(주/야간, 우천 등)의 주행 영상을 사용하였다.

2) 기존 모델 대비 성능 비교

이 프로젝트에서 수행한 자체 데이터 수집 및 파인 튜닝 과정의 필요성을 입증하기 위해, 기본 모델(YOLOv8n-coco)과 커스텀 모델(best.pt)의 성능을 비교 해보았다.

2. AI 모델 객체 인식 및 성능 평가

(i) 모델 정확도 검증 및 목표 달성 확인

학습이 완료된 최종 모델의 성능을 평가한 결과는 아래와 같다.

- mAP50: 97.296%
- mAP50-95: 87.02%
- 정밀도: 96.05%
- 재현율: 91.7%

이는 서론에서 설정한 성능 목표치인 정확도(mAP) >80%를 초과 달성한 수치이다. 특히 mAP50-95 지표가 약 87%인 것은 차량과의 거리나 크기가 변하더라도 일관되게 높은 탐지 성능을 유지함을 의미한다.

(ii) 기존 모델 대비 성능 향상 분석


모델 구분	mAP50	mAP50-95	주요 특징 및 분석
기본 모델	0.0049(0.4%)	0.0029(0.2%)	- 데이터 불일치: 차량과 도로 등을 전혀 인식하지 못함. - 클래스 불일치: 차선 클래스가 존재하지 않아 인식이 불가능하다.
커스텀 모델	0.97296(97.296%)	0.8702(87.02%)	- 실제 데이터 학습을 통해 mAP50, mAP50-95 각각 약 240, 435배의 성능 향상을 보였다.

[표 IV-2] 기본 모델과 커스텀 모델의 객체 인식 성능 비교 분석

위 결과에서 알 수 있듯이, 일반적인 객체 인식 모델을 그대로 사용할 경우 거의 무용지물에 가깝다. 반면, 커스텀 모델은 약 97.3%, 87%의 높은 정확도를 기록하여 실제 시스템으로 활용 가능성을 정량적으로 입증하였다.

(iii) 실제 주행 환경 정성적 평가

수치적인 성능뿐만 아니라 실제 주행 영상에서의 탐지 능력을 검증하기 위해, 학습에 사용되지 않은 별도의 주행 영상을 통해 정성 평가를 수행하였다.




[그림 IV-1] 차량 밀집 구간에서의 다중 객체(차량, 차선) 인식 테스트 시연

차량 밀집 구간에서도 전방 차량뿐만 아니라 인접 차선의 차량까지 정확히 인식하는 모습이 보였다. 차선도 끊임없이 인식하고 있는 모습을 보였다.

3. 클라우드 인프라 및 시스템 성능 평가

(i) 실시간 추론 속도 및 종단간 지연 시간 측정

- 평균 추론 속도: AWS EC2(t3.small) 인스턴스에서 이미지 1장당 평균 처리 시간은 120ms로 측정되었다. 이는 목표치인 150ms 보다 약 20% 빠른 속도로 목표를 달성했다는 것을 확인시켜준다. 다만, 시속 100km 주행 시 0.12초 동안 차량이 약 3.3m를 이동한다는 점을 고려할 때, 현재의 처리 속도는 빠르게 이동하는 객체의 현 위치를 동시성 있게 표시하는 데에는 무시할 수 없는 시차로 작용할 수 있음을 보여준다.
- 종단간 지연 시간: 스마트폰에서 이미지가 캡처된 시점부터 분석 결과가 GCP Cloud SQL에 저장되기까지 소요되는 총 시간은 1초 이하를 기록하였다. 저장된 파일명과 timestamp를 확인한 결과 1초 이내로 저장되었다는 것을 알 수 있다. S3를 버퍼로 사용하는 비동기 방식을 채택했음에도 불구하고, 목표치인 2초 이내를 만족시켰다.



Timestamp	Image ID	Processing Time (ms)
2025-11-30 12:19	20251130_121932	127.93
2025-11-30 12:19	20251130_121935	135.15
2025-11-30 12:19	20251130_121942	141.79
2025-11-30 12:19	20251130_121939	132.98
2025-11-30 12:19	20251130_121946	130.73
2025-11-30 12:19	20251130_121949	138.45
2025-11-30 12:19	20251130_121953	133.08
2025-11-30 12:19	20251130_121956	172.79
2025-11-30 12:20	20251130_122000	135.12
2025-11-30 12:20	20251130_122004	134.33
2025-11-30 12:20	20251130_122008	

[그림 IV-2] 실시간 추론 소요 시간 및 데이터 적재 시각이 기록된 로그 데이터


(ii) 오토 스케일링 부하 분산 테스트

트래픽 폭증 상황에 대한 시스템의 탄력성을 검증하기 위해, Apache Benchmark를 활용하였다. 가상 사용자 500명이 300000건의 요청을 보내도록 설정하고 부하 테스트를 돌렸을 때, 아무런 일도 일어나지 않았다. CPU에 추가적인 부하를 설정하기 위해 CPU stress를 활용했다.

- 반응성: cpu stress를 비공개 backend에서 동작시키고 Bastion에서 1000명의 사용자가 50만건의 요청을 보내도록 하였더니 1분 4초만에 새로운 EC2 인스턴스가 생성되었

다. 이는 목표인 3분 이내에 부합한다.

- 시스템 안정성: 이와 같은 확장이 진행되는 동안 연결 끊김이나 서비스 중단은 발생하지 않았다.



[그림 IV-3] 트래픽 부하 테스트에 따른 Auto Scaling 그룹의 인스턴스 자동 확장 이력

V. 결론 및 제안

1. 연구 결과 요약

본 연구는 스마트폰의 제한된 컴퓨팅 자원과 발열 문제를 해결하고, 국내 도로 환경에 최적화된 객체 탐지 서비스를 제공하기 위해 '클라우드 기반의 하이브리드 AI 블랙박스 시스템'을 설계 및 구현하였다.

기존 스마트폰 처리 방식의 한계를 극복하기 위해 추론 연산을 AWS 클라우드로 이관하는 구조를 채택하였으며, 이를 통해 스마트폰은 단순 이미지 수집 및 뷰어 역할에 집중함

으로써 장시간 주행 시에도 안정적인 구동을 확인하였다.

범용 모델(YOLOv8n-coco)의 낮은 차선 인식률(mAP 0.4%) 문제를 해결하고자 국내 주행 영상을 직접 수집·가공하여 파인 튜닝을 진행하였다. 그 결과 mAP50 기준 약 97.3%의 높은 정확도를 달성하였으며, AWS t3.small 인스턴스 환경에서도 평균 120ms의 추론 속도를 기록하여 실시간 위험 감지 시스템으로서의 가능성을 입증하였다.

또한 시스템 운영 측면에서도 트래픽 부하에 따라 서버가 자동 증설되는 오토 스케일링 환경을 구축하고, 최종 데이터가 GCP Cloud SQL로 적재되는 이기종 클라우드 파이프라인의 정합성을 검증하였다.

2. 연구의 의의

본 프로젝트의 기술적, 사회적 의의는 다음과 같다.

첫째, 모바일 하드웨어 스펙의 탈피이다. 고가의 최신 스마트폰이 아니더라도 통신망만 연결되어 있다면 클라우드의 강력한 리소스를 활용하여 고성능 AI 서비스를 이용할 수 있음을 증명하였다. 이는 디바이스 성능 격차를 해소하는 ‘AI 기술의 보편화’ 관점에서 의의가 크다.

둘째, 로컬 데이터 기반의 맞춤형 모델 확보이다. 해외 데이터셋에 의존하지 않고 세계 각국의 도로 및 차선 환경에 특화된 데이터셋을 구축함으로써, 실제 다양한 주행 환경에서 유의미하게 작동하는 실용적인 모델을 확보하였다.

3. 한계점 및 향후 발전 방향

본 연구는 대학생 수준의 제한된 예산과 AWS, GCE 프리티어 인프라 환경에서 개념 증명을 수행하였기에 성능과 비즈니스 모델 측면에서 타협점이 존재했으나, 향후 상용화 단계에서는 다음과 같은 기술적 고도화와 구독형 비즈니스 모델 도입을 통해 지속 가능한 서비스로 발전시킬 수 있다.

(i) 기술적 고도화

첫째, 인프라의 수직적 확장을 통한 초저지연·고화질 시스템 구축이다. 현재는 비용 효율성을 위해 CPU 기반의 보급형 인스턴스(t3.small)를 사용하여, 입력 이미지를 저화질로 압축하고 전송 주기를 3초(0.33fps)로 제한 할 수밖에 없었다. 하지만 향후 상용화 단계에서 실시간 추론 성능을 극대화 하기 위해 GPU가 탑재된 고성능 인스턴스(AWS g4dn 등)를 도입한다면, FHD(1080p)급 원본 화질을 압축 없이 실시간으로 처리가 가능하다. 이를 통해

추론 주기를 현재의 3초에서 0.5초(2fps) 혹은 그 이하로 단축시킬 수 있다. 이는 시속 100km 주행 시 약 83m마다 전방을 분석하던 것을 약 14m 단위로 정밀 분석하게 됨을 의미한다.

둘째, 데이터 중심 AI로의 고도화이다. 현재 모델은 기본적인 바운딩 박스 라벨링을 기반으로 학습되었다. 향후 연구에서는 객체의 외곽선을 픽셀 단위로 따는 세그멘테이션 기법이나, 차량의 종류(승용/화물/버스)와 차선의 곡률까지 식별하는 정교한 라벨링 작업을 수행해야 한다. 더 양질의 데이터셋을 통해 학습된 모델은 복잡한 도심 도로나 악천후 상황에서도 자율주행 레벨에 준하는 상황 판단 능력을 갖추게 될 것이다.

셋째, 네트워크 의존성 해결을 위한 엣지-클라우드 하이브리드 결합이다. 모든 연산을 클라우드에 의존하는 현재 방식은 통신 음영 지역(터널 등)에서 취약할 수 있다. 평상시에는 고성능 클라우드를 사용하되, 통신 지연이 감지되면 스마트폰 내부의 경량 모델이 즉시 개입하는 '적응형 하이브리드(Adaptive Hybrid)' 시스템으로 고도화하여 서비스의 연속성을 보장해야 한다.

(ii) 서비스 상용화 및 비즈니스 모델

기술적 최적화가 실현된다는 전제하에, 클라우드 운영 비용(GPU 서버 및 트래픽)을 충당하고 수익을 창출하기 위한 구독형 요금제를 제안 할 수 있다. 주요 타겟 고객층의 니즈를 분석하여 다음과 같은 가격 차별화 전략을 수립하였다.

첫째, 사회초년생을 위한 '베이직(Basic) 플랜' (월 9,900원) 첫 차 구매로 인해 경제적 부담을 느끼지만 안전에 민감한 20~30대를 타겟으로 한다. 기존 고가의 장비 구매 비용(을 대체할 수 있도록 진입 장벽을 낮추었으며, 전방 카메라 실시간 모니터링 및 블랙박스 기능을 제공하여 커피 2잔 값으로 심리적 만족감을 제공한다.

둘째, 중고차 구매자를 위한 '스탠다드(Standard) 플랜' (월 29,900원) 보증 기간이 끝난 중고차를 구매하여 유지비 절감에 관심이 많은 30~50대를 타겟으로 한다. 베이직 플랜에 추가로 차량의 이상 징후를 사전에 탐지하는 예방 정비 리포트를 제공하며, 안전 운전 점수와 연동하여 제휴 보험료를 10~15% 추가 할인받을 수 있는 혜택을 설계한다. 이를 통해 '구독료보다 더 큰 비용 절감 효과'를 체감하게 한다.

셋째, 고령 운전자를 위한 '실버 케어(Silver Care) 플랜' (월 19,900원) 인지 능력 저하로 인한 사고 위험과 그에 따른 보험료 할증(연령 할증) 문제를 겪는 65세 이상 고령층을 타겟으로 한다. 차선 이탈 및 졸음운전 감지 시 운전자와 보호자에게 즉시 알림이 가는 기능을 추가하여, 고령 운전자의 면허 유지를 위한 보조 수단이자 자녀들의 효도 상품으로 포지셔닝한다.

결론적으로 본 프로젝트는 단순한 기술 구현을 넘어, '클라우드 AI 기술의 대중화'를 통해 하드웨어의 제약을 극복하고, 세대별 맞춤형 구독 모델을 통해 경제적·사회적 가치를 동

시에 창출할 수 있는 지속 가능한 플랫폼으로의 확장성을 목표로 할 수 있다.

VI. References

- [1] <https://www.segye.com/newsView/20240908507930>
- [2] <https://www.yna.co.kr/view/AKR20240629038000003>
- [3] <https://www.hankyung.com/article/202406300811Y>
- [4] https://www.hani.co.kr/arti/economy/economy_general/1148009.html